

Rapport

1) Mål & valt spår.

Målet var att snabbt kunna identifiera område med höga bostadspriser för att kunna prioritera dessa. Jag valde spår B då jag kände att jag hade bättre koll på regression än klassificering och ville därför lära mig mer djupgående om det.

2) EDA

Median_house_value är högerskevt fördelad och många områden ligger vid maxgränsen på 500 000. Det finns också en tydlig relation mellan median_income och median_house_value där högre inkomst ofta innebär högre bostadspriser.

3) Metod

Datan delades upp i train och test för att kunna lära sig utifrån train-delen och utvärdera på data den inte sett alltså test-delen.

Datan delades upp med hjälp av train_test_split med 20% i test_size och 80% i train.

Modellerna utvärderades sedan med cross-validation för att få en bättre generell uppskattning av prestandan. Jag testade LogisticRegression som baseline, RandomForest och KNN eftersom vi tidigare gått igenom dessa modeller.

Som metric valde jag f1 eftersom den balanserar precision och recall.

4) Resultat

RandomForest hade högst medelvärde och samtidigt låg standardavvikelse. KNN hade lägst standardavvikelse och nästa samma medelvärde som LogReg, så det hade blivit min andra modell att utvärdera med tuning.

Resultatet efter tuning valde jag inte parametrarna som hade bäst rank_test_score då jag såg att det skiljde 4 procentenheter från test-score och train-score. Jag letade därför upp i listan om det fanns någon annan variant som hade liknande test score fast lägre standardavvikelse för att få en mer stabil modell.

Testdatan blev sämre på precision, något bättre på recall och något sämre på F1. Detta efter jag justerat threshold till 0.35. Vill man justera någon metric t.ex. höja recall kan man sänka threshold för att hitta fler högprisområden men till priset av att man får fler falsklarm. Jag hade i åtanke från början att RandomForest förmodligen hade överanpassat då den nästan hade 10 procentenheter högre medelvärde än de andra två modellerna.

5) Rekommendation

Jag valde RandomForest som slutlig modell eftersom den presterade bäst av de testade modellerna i cross-validation. Efter optimering av hyperparametrar uppnådde modellen en bra balans mellan precision och recall samt ett högt f1-score på testdata. Med en threshold på 0.35 blev modellen stabil och fångade högprisområden utan att generera för många falsklarm.

En lägre threshold på 0.23 gav högre recall vilket innebär att den hittade fler högprisområden men detta skedde på bekostnad av fler falsklarm och ett lägre f1-score. Jag bedömer därför att modellen är lämplig att ta vidare för att prioritera nya områden för vidare analys.

6) Risker & begränsningar

Det kan vara lätt att missa saker som t.ex. fylla i NaN värden innan man har delat upp datan i train/test. Då riskerar man att räknar ut t.ex. medianen även på testdatan vilket gör att modellen får information den inte borde ha.

Om target är obalanserad, t.ex. att 10% är klass 1 resten är klass 0. Kan det också bli problem. Om man delar upp datan utan att ta hänsyn till detta kan vissa delar få väldigt positiva exempel vilket gör att modellen lär sig fel. Därför är det viktigt att använda t.ex. Stratified KFold så att fördelningen av klasser blir mer rättvis i varje del.

7) Oövervakad inlärning

Oövervakad inlärning används för att hitta mönster utan att ha en target.

I detta caset kan det användas för att som om det finns grupper av områden.

Pca används för att reducera dimensioner och visualisera datan. Klustring används för att hitta grupper av liknande datapunkter. En risk när man använder pca är att mönster kan försvinna om man reducerar för mycket. En risk med klustring är att det kan vara svårt att avgöra hur många kluster datan bör delas in i. KMeans delar alltid upp datan i det antal kluster du anger även om det inte finns tydliga grupper i datan. Detta kan leda till otydliga eller missvisande kluster om datapunkterna inte är tydligt separerade.

Felanalys: I detta case är FN viktigare eftersom det innebär att modellen missar högprisområden. Dock vill man inte ha för många falsklarm och lägga prioriteringar på fel områden i onödan. Genom att sänka threshold kunde modellen fånga fler högprisområden (högre recall) men detta ledde samtidigt till fler falsklarm (FP).

Kritisk diskussion: Modellen är tränad på den data vi har nu och det finns en risk att den inte fungerar lika bra om ny data ser annorlunda ut. T.ex. kan relationen mellan inkomst och bostadspris ändras med tiden. Ett nästa steg hade varit att testa fler modeller eller justera threshold ännu mer beroende på hur modellen ska användas i praktiken.

8) Självreflektion

Jag tycker att jag har gjort ett bra jobb med att gå igenom hela processen från EDA till modellval. Jag har också testat olika modeller, gjort hyperparametertuning och analyserat hur threshold påverkar resultatet. Detta gav mig en bättre förståelse för hur modellen fungerar i verkligheten. Det svåraste var att förstå hur olika metrics hänger ihop och hur man ska tolka dessa. Jag bedömer att min inlämning motsvarar VG eftersom jag har visat förståelse för hela processen och även tagit med oövervakad inlärning tillsammans med "fördjupning i metod".